



新疆师范大学学报(哲学社会科学版)

Journal of Xinjiang Normal University(Edition of Philosophy and Social Sciences)

ISSN 1005-9245,CN 65-1039/G4

《新疆师范大学学报(哲学社会科学版)》网络首发论文

题目：自然语言处理研究综述
作者：赵铁军，许木璠，陈安东
DOI：10.14100/j.cnki.65-1039/g4.20230804.001
收稿日期：2023-06-23
网络首发日期：2023-08-04
引用格式：赵铁军，许木璠，陈安东. 自然语言处理研究综述[J/OL]. 新疆师范大学学报(哲学社会科学版). <https://doi.org/10.14100/j.cnki.65-1039/g4.20230804.001>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

自然语言处理研究综述

赵铁军 许木璠 陈安东

(哈尔滨工业大学 计算学部, 黑龙江 哈尔滨 150001)

摘要:近年来,自然语言处理(NLP)因在分析与建模人类语言任务上的诸多成果而备受关注。当前,大规模预训练语言模型展现出强大的对话问答、文本生成能力,带来自然语言处理研究的新一轮热潮。自然语言处理在机器翻译、文本摘要、信息抽取等各领域应用广泛。本文首先讨论自然语言处理针对语言学四个不同层次文本信息的分析手段,对自然语言处理的基本任务组成进行概述。其次,讨论自然语言处理在具体下游任务中的应用现状,包括自然语言处理在具体任务中的应用历史、当前的研究趋势以及面临的挑战。最后,在大规模语言模型研究对数据集提出更高要求的背景下,对自然语言处理领域已有的数据集及评测基准集等进行讨论。

关键词:自然语言处理;句法分析;语义分析;机器翻译;问答系统;信息抽取

中图分类号: TP391.1 **文献标识码:** A **文章编号:** 1005-9245(2024)01-0000-00

一、引言

自然语言处理(Natural Language Processing, NLP)是计算机科学、人工智能和语言学等学科交叉的前沿领域。其目标是让计算机能够理解、处理和生成自然语言,使计算机具有类似人类的语言交互和文本理解能力。NLP技术的应用范围广泛,包括机器翻译、智能客服、智能搜索、自动文摘、情感分析、语音识别、问答系统,等等。近年来,NLP领域取得了巨大进展,主要得益于深度学习技术的发展以及互联网海量的文本数据。深度学习技术在NLP领域的应用涉及词向量表示、语言模型、机器翻译、文本分类、命名实体识别等任务。此外,随着开源软件的不涌现,例如,TensorFlow、PyTorch等,使研究人员和开发者能更便利地实现和部署NLP算法。

语言可定义为一组规则或符号集,其中,符号被组合并用于传递信息。并非所有用户都精通特定

机器语言,NLP为没有时间学习新语言或完美掌握它的用户提供服务。NLP可分为自然语言理解和自然语言生成两部分,分别对应理解文本和生成文本的任务。NLP与语言学紧密相关,语言学包括音韵学,即声音;词汇学,即词形成句;法学,即句子结构;语义学,即语法语用;学,即理解。自然语言生成是产生有意义的短语、句子和段落的过程。NLP的主要目标是使计算机能理解和使用自然语言,从而为用户提供更好的交互体验和更高效的工作方式。

大规模预训练语言模型又称大语言模型(Large Language Models, LLMs),自2018年起,其为自然语言处理领域带来了新的机遇和挑战。使用“预训练大模型+微调大模型”的学习范式可在几乎所有自然语言处理任务中取得领先效果,研究者只需用预训练大规模语言模型在下游任务标注数据集上进行微调,即可获得较好的任务性能。2022年年底,横空出世的ChatGPT使自然语言处理任

收稿日期: 2023-06-23

基金项目: 本文系国家自然科学基金联合基金项目“人机协同翻译方法及关键技术研究”(U1908216)的阶段性成果。

作者简介: 赵铁军,哈尔滨工业大学计算学部二级教授、博士生导师;许木璠,哈尔滨工业大学计算学部博士研究生;陈安东,哈尔滨工业大学计算学部博士研究生。

务以更加便捷的形式被解决。大规模预训练语言模型采用端到端的训练方法，通过大量神经元参数拟合预训练海量数据中包含的信息。这一方法有效规避了依赖人工设计特征的传统语言模型的性能限制，能自主学习语言的内在表示，同时，带来可解释性以及安全性方面的问题。如何能用更加细致的模型分析和可视化技术理解与解释大模型的内部机制和预测结果，如何避免模型生成有偏见的、有害的文本，已成为围绕大模型开展的新兴研究方向。此外，由于大模型的性能在很大程度上依赖预训练语料库的文本数量和质量，因此，大模型的出现对自然语言处理任务的数据集提出更高要求。

在此背景下，本文第二部分将从词法分析到语义分析，自下而上地总结不同层次的文本处理技术；第三部分针对不同应用场景下的下游任务研究进展进行介绍，包括总结深度学习、大语言模型给自然语言处理领域任务带来的发展以及未来的挑战；第四部分对已有的任务评估指标、数据集、测试基准任务集合进行总结。笔者通过总结已有的文本分析手段、下游任务开展方式、公开数据集及评测手段，为后续开展自然语言处理研究提供有益参考。

二、自然语言处理的语言学基础

在研究自然语言处理时，语言学基础是研究者理解和分析人类语言的基石。语言学提供了对词法、语法、语义和语用等语言现象的系统研究和描述，为 NLP 任务提供了重要的理论基础。其中，词法研究单词及其形态学变化，语法研究句子结构和成分间的关系，语义研究词语和句子的意义，语用研究语言在上下文中的使用和交流目的。

在 NLP 中，理解和解析人类语言的核心挑战在于语言的复杂性和多义性。语言具有丰富的含义和上下文依赖性，一个词语可以有多种词义，一句话也可以根据语境产生不同的解释。语言学的基本概念和理论有助于解决上述挑战，从而更好地处理文本数据。通过深入研究语言学基础，人们可以了解自然语言中的结构和规律，并将这些知识应用于 NLP 任务。例如，语法知识可用于句法分析和依存关系识别，语义知识可用于词义消歧和语义角色

标注，语用知识可用于指代消解和语境理解。

总之，语言学基础为研究者提供了一种理论框架，使人们能更好地理解 and 处理自然语言。在 NLP 任务中，语言学的基本概念和方法为探索语言的复杂性和多样性以及为构建更准确、更智能的自然语言处理模型和系统奠定了基础。

（一）词法分析

对自动词汇分析的需求可以追溯到 20 世纪 50 年代，当时，需要对语言编译器进行编程，以识别变量名和保留词，并为每个变量和保留词分配适当的角色。计算机开始用于处理自然语言文本，就需要词汇处理提取、识别、组织和关联单词和短语。起初，用于术语识别的词典由手工编制，或改编自现有的词典或列表，后来开发了自动工具，要么直接生成词典，要么减少构建词典所需的人力。词法分析（Lexical Analysis）对词与词之间的联系进行分析，从而获得对文段局部表达信息的抓取。词法分析是大多数自然语言处理任务的第一步，能帮助研究者将输入文本或一系列字符打上词汇标签。这些标签被称为 Token，在词法分析过程中，研究者尝试通过分析手段对每个单词进行识别并为其打上合适的词汇标签。

最基础的标签标注方式是赋予每个单词一个词性标签（Part-of-Speech, POS 标签）。词性标注比在词典中查找出当前单词及其词性更加复杂，因为有的单词可在不同语境下具备多种词性。这在英文中较为常见，例如，复数名词“dogs”也可以表示“纠缠，跟踪”等动词含义。因此，标注词性标签时，研究者要对单词的结构、所在上下文进行分析，以了解其确切词性。词性标注任务是将给定句子中的每个单词从给定标签组（Tag Set）中赋予词性标签（Part-of-speech Tag）。1993 年，由 Marcus 等提出 Penn Treebank 项目，提供对英文文本的词性标签集合^①，包括 36 种英文词性标签和 12 种特殊字符标签。中文词性标注任务由 Ng and Low 在 2004 年提出。任务目标是在联合分割标注的任务中，计算基于词级别的精确率和召回率以及 F1 分数。标签组使用 33 类中文词性集合，数据集包括我国新华社、香港新闻等新闻文本。早期词性标注工作多使用基于隐马尔可夫模型的序列标注方法，例如，1994 年前后 Garside 的 CLAWS 词性标注系

^① Marcus, M., Santorini, B., Marcinkiewicz, M. A. Building a Large Annotated Corpus of English, The Penn Treebank, 1993.

统^①。在神经序列模型兴起后,最新研究成果集中在使用条件随机场 CRF 以及循环神经网络、BERT 模型进行序列词性标注工作。2020 年,Tian 等提出基于知识以及注意力机制的汉语词性联合标注方法^②,取得了较好的标注效果。

此外,词法级别的分析可进行包括词形还原(Lemmatization)、停用词删除等一系列操作。词形还原是将一个单词以曲折形式归类的方式,识别一个单词在特定语境下的语义并依此将其还原为元形态。停用词删除是针对在后续自然语言分析过程中筛除不需要的词汇,例如,在英文语义分析过程中去除“the”等无实际含义的修饰词。对词形还原可使用条件随机场 CRF 等方式进行对词汇语义的判断,停用词更多依据人为规定的停用词表进行查表筛除。

(二) 文本组块分析

在词汇层面进行词性标记后,单词被分组为短语。句法级别的分析通过分析句子的语法结构获知句子的正确构成,涉及短语和句子的结构以及短语或句子中单词之间的关系^③。句法分析的输出是揭示单词之间结构依赖性的句子,考察词汇层面未考虑的单词语序、停止词、形态和词性。例如,改变语序会改变单词之间的依赖关系,也可能影响句子的理解。句法分析要求输入保留原始文本形态,即与词形还原以及停用词筛除等操作不兼容——这些操作会改变原有句子的意思以及让词汇丧失其语法特征。由于一些句法分析手段基于词法分析结果,因此,在诸多研究中将词法分析归类为句法分析中的子任务。除上述词性标注任务以及词形还原任务外,句子级别的句法处理任务较典型的是文本组块分析、依存解析,等等。

文本组块分析将句子分割成不重叠的部分,并且依据句法作用给单词打上句法作用标签,例如,名词短语(NP)和动词短语(VP)。文本组块分析可帮助机器学习句子结构和单词之间的关系,为下游自然语言处理任务提供有效的信息基础。这些下游自然语言处理任务要对句子成分进行一般理解,例如,命名实体识别 NER、文本摘要和情绪分析,等等。

Ramshaw 和 Marcus 第一次提出将文本组块标注作为机器学习问题处理^④。此前,组块结构大多用单词间的括号进行编码,会出现括号不平衡的问题。为解决这一问题,他们引入 IOB1(或称 IOB)标记模式表示块结构,其中,“B”表示紧接另一个块的开头,“I”表示单词在块内,“O”表示任何块外。因此,文本分块开始被当作序列标注问题进行处理。此外,另一种主要的编码模式是 BIES(BILOU)^⑤,其中,“E”表示块的结束标记,“S”表示单个元素。研究表明,使用 BIOES 的组块显著优于使用 IOB 的组块^⑥。

文本分块的标注方法可分为基于特征工程的方法和基于深度学习的方法。基于特征工程的方法用上下文信息人工提取特征集合,常见特征包括词汇信息、词性标签以及上文已标注的单词标签。早期文本组块分析领域研究多使用一次预测序列中一个单词标签的方法,利用不同词汇和句法信息作为特征以作出最佳的局部决策。Ramshaw 和 Marcus[6]提出一种基于转换的学习方法。组块结构由 IOB1 标签模式表示,在名词/动词短语分离中由 BN、N、BV、V、P 表示。Johnson 和 Zhang 提出一种文本分块的半监督方法,该方法基于好的分类器应具有相似的预测结构的思想,从辅助分类问题中学

- ① Garside, R. 11 the robust tagging of unrestricted text: The BNC experience, Using corpora for language research: Studies in honour of Geoffrey Leech, 1996: 167.
- ② Tian, Y., Song, Y., Ao, X., et al. Joint Chinese word segmentation and part-of-speech tagging via two-way attentions of auto-analyzed knowledge, Proceedings of the 58th annual meeting of the association for computational linguistics, 2020: 8286-8296.
- ③ Woolf, B. P. Building intelligent interactive tutors: Student-centered strategies for revolutionizing e-learning, Morgan Kaufmann, 2010.
- ④ Ramshaw, L. A., Marcus, M. P. Text chunking using transformation-based learning, Natural language processing using very large corpora, 1999: 157-176.
- ⑤ Ratnikov, L., Roth, D. Design challenges and misconceptions in named entity recognition, Proceedings of the thirteenth conference on computational natural language learning, 2009: 147-155.
- ⑥ Yang, J., Liang, S., Zhang, Y. Design challenges and misconceptions in neural sequence labeling, arXiv preprint arXiv: 1806.04470, 2018.

习好的结构有助于提高目标问题的性能^①。

较新的部分研究采用全局分类方法对整个序列的标签进行优化。Sha 和 Pereira 首次将条件随机场 CRF 应用于文本分块任务中，提出一种新的具有更好收敛性的文本分块算法^②。Muis 和 Lu 提出一种用于对用户生成的文本进行 NP 分块的弱半马尔可夫 CRF 模型^③。在 Semi-CRF 的基础上，引入一个较弱的变体，该变体限制每个节点或连接到 L 个单词外的同一标签的节点，或连接下一个单词中的所有节点^④。Lin 等认为，编码模式的选择会影响序列标记模型的性能，因此，提出双潜在变量 CRF (LVCRF)，可自动为给定的输入句子选择最佳编码模式^⑤。他们在 IOB2 和 BIOES 分块模式上测试了上述模型。潜在变量 CRF 通过基于概率链式法则在输入和输出之间插入一组变量实现，使模型能捕捉观察实例和标签之间的潜在关联结构。

作为序列标注问题，CNN、RNN 和 LSTM 等神经网络模型均可应用于文本分块任务。2017 年，Zhai 等提出一种基于 Bi-LSTM 的文本序列分块模型^⑥，其中，每个分块被视为用于标记的完整单元。他们将序列标记分为两个子任务：分割和标记。前者是明确的识别块的范围，后者基于分割结果将每个块标记为单个单元。Sun 等提出一种用于多视图序列标记的混合神经 CRF^⑦，称为 MVCRF，并采用不同的神经网络进行多视图特征提取。该模型不仅考虑了邻域标签之间的相关性并联合解码最佳标签序列，而且利用一致性和互补性原理结合多视图学习。Wei 等提出位置敏感自我注意力机制 (PSA)^⑧，以解决基于 RNN 方法在捕捉句子中

离散关系方面的局限性。该模型的核心是基于 Bi-LSTM 的上下文编码器，在这一编码中使用自注意机制编码相对位置信息。与特征工程方法相比，深度学习能自动提取特征，并促进与其他序列标记任务的联合训练。

(三) 句法及语义结构分析

人类依赖语言知识和句子中的概念理解一句话的意思，但机器并不能直接通过文本序列理解这些概念。句子级别的语义结构分析是自然语言处理领域的重要研究话题，这些分析能帮助研究者揭示句子内部结构间的关联关系，从而更好地帮助研究者用结构化数据表征自然语言文本中的语义信息。与句法分析相比，由于谓词论证等各种语义的复杂结构，语义分析较为困难，这是 NLP 的一个长期目标。语义分析通过处理句子的逻辑结构识别密切相关的单词，以理解句子中单词或不同概念间的相互作用，从而确定句子的可能含义。常见的语义结构分析手段包括成分分析 (Constituent Parsing)、依存分析 (Dependency Parsing) 以及语义依存图 (Semantic Graph Parsing)，等等。

成分分析是语法分析的一项基本任务，长期以来受研究者的关注。成分分析任务是揭示句子中短语之间的关系。成分分析任务的标准评估可基于短语的标签正确性计算，其中，精度、召回率和 F1 测量分数为主要指标。成分分析的主流方法包括基于图表 (Chart-based) 的模型和基于转换的模型。目前，神经模型在上述两种方法指导下都取得了最先进的性能。

基于图表方法主要训练分类器对一定窗口大小

- ① Johnson, R., Zhang, T. A high-performance semi-supervised learning method for text chunking, Proceedings of the 43rd annual meeting of the Association for Computational Linguistics (ACL'05), 2005: 1-9.
- ② Sha, F., Pereira, F. Shallow parsing with conditional random fields, Proceedings of the 2003 human language technology conference of the North American chapter of the association for computational linguistics, 2003: 213-220.
- ③ Muis, A. O., Lu, W. Weak semi-markov CRFS for NP chunking in informal text, arXiv preprint arXiv: 1810.08567, 2018.
- ④ Sarawagi, S., Cohen W. W. Semi-markov conditional random fields for information extraction, Advances in neural information processing systems, 2004: 17.
- ⑤ Lin, J. C. W., Shao, Y., Zhang, J., et al. Enhanced sequence labeling based on latent variable conditional random fields[J]. Neurocomputing, 2020: 431-440.
- ⑥ Zhai, F., Potdar, S., Xiang, B., et al. Neural models for sequence chunking, roceedings of the AAAI conference on artificial intelligence. 2017(1).
- ⑦ Sun, X., Sun, S., Yin, M., et al. Hybrid neural conditional random fields for multi-view sequence labeling, Knowledge-Based Systems, 2020: 105151.
- ⑧ Wei, W., Wang, Z., Mao, X., et al. Position-aware self-attention based neural sequence labeling, Pattern Recognition, 2021: 107636.

内的成分进行预测,较早的成分分析手段使用基于统计的方法,基于上下文无关文法对当前语句块成分进行预测。但这些模型难以融合全局特征,因为在解编码过程中,未来的决策不可见。使用条件随机场方法是全局建模的一种方法。Hall等提出一个强大的成分解析模型,通过将标准的N-gram CRF模型用于上下文无关文法框架,预先提供丰富的复杂先验特征^①。可对相邻上下文无关文法规则间的依赖关系进行建模,从而应用于全局推理。2010年,Socher等首次提出使用循环神经网络解决序列成分分析问题^②。Stern等使用深度双向LSTM增强感知表征,设计复杂的跨度表征策略^③。同时,他们采用自上而下的增量解析进行解码,淡化了基于图表和基于转换的方法之间的差异。后续预训练语言模型如BERT能获得最好的解析效果。

基于转换的方法采用逐步转化的方式进行,每一步决策器将会基于已有的转化所完成的成分序列(状态State)决定对真实序列下一成分的操作(动作Action),例如,合并上一个成分、创建一个新成分标签,等等。使用该方法的特征包括上下文词汇化单词、POS标签、距离,等等。Watanabe等基于上述思路将模型替换为神经网络模型^④,取得了较好的效果。Kitaev等提出Tetra标记系统^⑤,该系统结合序列标记和过渡动作分类,在使用BERT表示的基准PTB数据集上实现了最先进的性能。

依存分析旨在根据输入句子生成一棵句法依存树。句法依存树是单词之间的一组有向边,这些有向边形成以ROOT为根的有向树结构。每条边都从父词(也称为头词)指向子词,同时,每条边都有明确的句法关系标签,例如,主语、宾语、修饰语,等等。依存分析在语义解析、机器翻译、关系提取和许多其他任务中都有应用,对机器理解语句

各部分的语义关联有较大帮助。对依存解析结果的评估主要使用依赖性准确度,即未标记标注得分(UAS)和标记标注得分(LAS)。在早期阶段,依存分析主要关注生成依赖关系树,后研究社区开始关注依赖关系图的生成。依存分析同样经历了从基于统计的方法到神经网络方法的过渡。早期基于图的方法利用最大生成树(MST)算法进行解码,该算法将完整地依赖树分解为小因素,如依赖边,并通过将所有包含因素的得分相加对完整树进行评分。每个因素的得分可通过从中提取的特征独立计算。使用依赖边作为基本评分因子的模型被称为一阶模型,其中,阶数表示因子中边的最大数量,多阶模型同样获得了较好的效果^⑥。除BERT模型外,还可使用基于图神经网络的方法预测依赖关系。此外,使用中心语驱动短语结构语法(HPSG)融合自注意力机制神经网络层的方法也取得了较好效果。

上述方法仅关注句子中的句法信息以及浅层语义信息,随着深度语义解析的需求越来越大,研究者逐渐开始关注语义依赖图的解析。语义依赖图仍由一组双重词汇化的依赖关系表征,图中的节点对应表层词汇,图中的边指示节点之间的语义关系。在这些研究中包含使用半监督训练方法的CRF自编码器的方法以及基于BERT表征的图神经网络语义关系图解析方法,等等。

(四)篇章级分析

句法和语义层面处理句子长度单位,在自然语言文本中通常多个句子之间存在逻辑关联,研究者要在单词和句子之间建立联系从而分析整体篇章的逻辑,以确保其连贯性。通过解释句子之间的关系与从多个层面揭示文本的语言结构展示整个篇章的语义信息。篇章级分析最常见的任务是共指消解,

- ① Hall, D., Durrett, G., Klein, D. Less grammar, more features, Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2014: 228-237.
- ② Socher, R., Manning, C. D., Ng, A Y. Learning continuous phrase representations and syntactic parsing with recursive neural networks, Proceedings of the NIPS-2010 deep learning and unsupervised feature learning workshop, 2010: 1-9.
- ③ Stern, M., Andreas, J., Klein, D. A Minimal Span-Based Neural Constituency Parser, Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2017: 818-827.
- ④ Watanabe, T., Sumita, E. Transition-based neural constituent parsing, Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), 2015: 1169-1179.
- ⑤ Kitaev, N., Klein, D. Tetra-Tagging: Word-Synchronous Parsing with Linear-Time Inference, Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020: 6255-6261.
- ⑥ Ma, X., Zhao, H. Fourth-order dependency parsing, Proceedings of COLING 2012: Posters, 2012: 785-796.

其目的是在一段文段或篇章中找到所有对同一实体的描述表达式。例如,(1)共指消解是自然语言处理任务之一,(2)这项任务旨在对同一实体的不同描述进行查找,(3)这一技术在较多的下游 NLP 任务中使用。人们可以很快理解(2)中的“这项任务”指的是(1)中的“共指消解”任务。对这一技术的进一步补充(3)同样应当正确指向“共指消解”这一名词实体。如此才能完善这三句话的语义结构。共指消解是各种 NLP 应用程序中的一个重要步骤,这些应用程序涉及各种 NLP 应用任务,例如,文档摘要、信息提取,等等。

在深度学习广泛应用前,文档中对实体的引用描述大多通过伯克利共指消解系统或斯坦福共指消解判别规则进行提取。因此,在进行共指消解任务时,有的系统采用用上述方法抽取好的对实体的引用描述,有的系统直接从原始文本开始分析。依据输入信息不同,将共指消解系统分为使用引用对模型、引用排序模型、基于实体的模型、隐含结构模型以及语言建模模型五类。2017 年, Lee 等首次提出端到端的共指消解模型^①, 其为一个双向 LSTM+ 线性打分层的模型, 直接从原文序列输入给每个小窗口大小内的文本打一个实体引用分数作为该窗口可能含有实体引用的程度评估。由于共指解析与现实世界中的先验知识密切相关, Aralicate 等利用关系提取系统^②和提取多任务强化学习技术, 为共指解析系统创建奖励系统。共指解析系统基于 Lee 等的研究成果, 使用基于三种不同关系提取系统产生的奖励的策略梯度和模型插值^③。每对关系提取系统捕获不同的关系方面, 并基于该方面

计算奖励, 最终奖励为单个样本奖励的归一化总和。2020 年, Joshi 等提出一种对 BERT 的优化模型 SpanBERT^④, 通过改变 BERT 的训练目标函数, 使 BERT 能对更长的文本切片进行整体嵌入表示学习。同年, Xu 等在 SpanBERT 的基础上使用高阶推理进行共指消解分析^⑤。一种思路是使用指代文本切片的表征作聚类获取共指集合。而 Liu 等探索出使用图神经网络直接进行共指预测的方法^⑥。

(五) 语用分析

语用分析是语言学的一个分支领域, 研究语言使用上下文、意义和交际效果。语用分析关注人们如何使用语言进行交流, 并探究语言在特定情境中的含义和功能。在语用分析中, 研究者关注四方面。

1. 言外之意

语用分析探讨言外之意, 即说话人所意味但未直接表达的含义^⑦。包括暗示、间接表达、隐喻和讽刺等语言现象。通过分析语言使用的语境和言外之意, 可以更好地理解人们之间的交流和沟通。

2. 语言行为

有研究者研究了语言的行为方面, 即语言的实际效果和影响。探讨了语言的目的、意图及其对听者行为的影响。例如, 请求、命令、道歉和赞美等语言行为都可通过语用分析进行研究。

3. 会话结构

语用分析关注会话结构, 即人们在对话中如何相互交流和组织话语。研究对话中的转换、话题管理、信息提供和反应, 等等。通过分析会话结构, 可以揭示人们在交流中的合作和协调策略。

① Lee, K., He, L., Lewis, M., et al. End-to-end Neural Coreference Resolution, Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, 2017: 188-197.

② Aralicate, R., Lent, H., González, A. V., et al. Rewarding Coreference Resolvers for Being Consistent with World Knowledge, Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), 2019: 1229-1235.

③ Lee, K., He, L., Zettlemoyer, L. Higher-Order Coreference Resolution with Coarse-to-Fine Inference, Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers), 2018: 687-692.

④ Joshi, M., Chen, D., Liu, Y., et al. SpanBERT: Improving Pre-training by Representing and Predicting Spans, Transactions of the Association for Computational Linguistics, 2020: 64-77.

⑤ Xu, L., Choi, J. D. Revealing the Myth of Higher-Order Inference in Coreference Resolution, Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2020: 8527-8533.

⑥ Liu, L., Song, Z., Zheng, X. Improving Coreference Resolution by Leveraging Entity-Centric Features with Graph Neural Networks and Second-order Inference, arXiv e-prints, 2020: rXiv: 2009.04639.

⑦ Carston, R., Wearing, C. Metaphor, hyperbole and simile: A pragmatic approach, Language and Cognition, 2011(2): 283-312.

4. 社会和文化因素

语用分析认识到社会和文化因素对语言使用的影响。在不同社会和文化背景下,语言的使用方式、礼貌原则和交际规范可能存在差异。因此,语用分析研究人们在特定社会和文化环境中如何使用语言及这些因素对交际的影响。

语用分析的方法包括观察、采访、问卷调查和语料库分析,等等。研究者使用这些方法收集和析实际语言使用的数据,并通过观察和解释了解语言交流的细微差别和复杂性。消除文本或实体命名歧义是语用层面面临的问题之一,例如,Gao 等的研究以消除或尽量减少歧义为最终目标^①。消歧任务更多与知识图谱、数据库等领域关联。

三、自然语言处理应用

(一) 自然语言处理应用现状概述

自然语言处理研究目标是使计算机能够理解人类语言,并实现自然语言与计算机程序之间的交互。近年来,基于深度学习技术在 NLP 领域得到广泛应用,在深度学习方向发展了如基于神经网络的语言模型、序列到序列模型、注意力机制,等等。上述技术的应用使 NLP 在处理文本数据方面取得了突破性进展,例如,机器翻译、信息抽取、文本分类、问答系统,等等。

实际上,Word2vec 技术的出现为自然语言处理领域应用研究带来显著变化,并将自然语言领域推向深度学习时代。虽然在 21 世纪初,神经语言模型已被提出,但其抓取语义信息、进行语义表征的能力有限。当时的模型通过给定前 n 个单词,确定下一个单词(标记)出现的概率。2003 年,Bendigo 等第一次将神经网络引入语言建模过程,基于前馈神经网络,通过学习单词序列的条件概率分布捕捉语言的统计特性^②。Collobert 等提出在 NLP 领域应用多任务学习的概念,使用两个卷

积模型和最大池化执行词性以及命名实体识别标记。在这一时期,人们将精力集中在研究特征工程和统计模型领域。这些方法需要依赖专家知识和人工构建的规则提取特征,对大规模文本数据的处理效率较低。

2013 年,Mikolov 等提出 Word2vec 方法,通过使用神经网络模型以无监督的方式从大规模文本语料中学习单词的分布式表示。这种分布式表示方式可捕捉到单词之间的语义和语法关系,将单词转化为具有语义信息的向量表示^③。Word2vec 可以使用 Skip-gram 和 CBOW 两种语言模型建模方式以更好地建模上下文和目标单词之间的关系。相比于以往的方式,Word2vec 能从大规模文本数据中自动学习单词的分布式表示,避免传统方法中手工设计特征的繁琐过程。Word2vec 的提出和成功应用,极大地推动了词嵌入研究的发展。它激发了更多研究者探索和提出改进的词嵌入模型,例如,GloVe、FastText,等等。这些模型在各种自然语言处理任务中取得了显著成果,丰富了对词语表示和语义关系的理解。

此后,随着深度学习技术的发展和计算资源的提升,神经语言模型取得了显著进展。有了将单词映射到语义向量空间的诸多方法,神经网络模型能获取更有效的文本语义表征输入,为其在自然语言处理任务中的应用奠定了基础。Sutskever 等提出一个用于序列到序列映射的通用框架,其中,使用编码器和解码器网络分别将序列映射为向量和将向量映射为序列。早期应用于图像领域的卷积神经网络(CNN)后来同样被用于解决与 NLP 任务相关的问题。例如,句子分类、情感分析、文本分类、文本摘要、机器翻译和问答系统,等等。Newatia 等尝试将各种形式的 CNN 模型获取上下文信息^④,Wang 和 Gang 总结了 CNN 在自然语言处理任务中的应用情况^⑤。循环神经网络(RNN)在 NLP 中已被广泛应用,并被证明对文本、时间序列、财

① Gao, T., Dontcheva, M., Adar, E., et al. Datatone: Managing ambiguity in natural language interfaces for data visualization, Proceedings of the 28th annual acm symposium on user interface software & technology, 2015 : 489-500.

② Bengio, Y., Ducharme, R., Vincent, P. A neural probabilistic language model, Proceedings of NIPS, 2001.

③ Mikolov, T., Chen, K., Corrado, G., et al. Distributed representations of words and phrases and their compositionality, /Advances in Neural Information Processing Systems, 2013.

④ Newatia, R. Sentence classification using convolutional neural networks, <https://medium.com/saarthi-ai/sentence-classification-using-convolutional-neural-networks-ddad72c7048c>.

⑤ Wang, W., Gang, J. Application of convolutional neural network in natural language processing, 2018 international conference on information Systems and computer aided education(ICISCAE), IEEE, 2018 : 64-70.

务数据、语音、音频、视频等顺序数据非常有效。LSTM 是 RNN 的修改版本,适用于需要长时间保留所需重要信息且丢弃不相关信息的情况。LSTM 的进一步发展产生了一个简单的变体,称为门控循环单元 (GRU),在许多任务中表现出较标准 LSTM 更好的结果。但卷积神经网络和循环神经网络在处理长序列时均有欠缺。卷积神经网络需要堆叠多个卷积层才能获取较长距离文本之间的关联信息,而循环神经网络在处理长序列输入时存在长距离信息遗忘的问题。

2017 年, Vaswani 等提出基于注意力机制的 Transformer 架构,自然语言处理领域又一次迎来重要变革。注意力机制的使用成功突破长序列文本处理的困境,使网络在训练中自适应地关注上下文的文本信息。使用 Transformer 架构的模型几乎在自然语言处理领域的各任务中取得超越以往性能的结果^①,近期火热的大语言模型几乎全部基于 Transformer 架构搭建。Transformer 具有学习更长期的语义依赖关系的能力,但原始的 Transformer 模型在语言建模过程中依然会受上下文输入长度的限制,无法处理超长序列。后续诸多改进方案,逐渐提升了 Transformer 对超长文本输入的处理能力。例如, Dai 等提出一种新的神经架构 Transformer-XL (XL 表示 Extra-long 超长),可实现学习超出固定长度的单词的依赖关系^②。Rae 等尝试压缩 Transformer 从而进行长序列学习^③。Otter 等总结了深度学习在 NLP 中的应用以及相关的最新工作^④。

跟随 Transformer 架构到来的是最新的预训练语言模型以及大规模语言模型的浪潮,越来越多的研究者尝试探寻对自然语言处理任务的统一模型解决办法。从 2018 年的 BERT 模型开始,人们使用

大规模预训练文本对模型进行训练后,在目标任务标注数据集上进行“预训练+微调”模型的学习范式^⑤。BERT 模型通过使用双向 Transformer 架构对输入文本进行深层次表示学习,提高了许多自然语言处理任务的性能。此后,基于 Transformer 的 NLP 研究持续取得重要突破。其中,关键进展是生成式预训练 Transformer (GPT) 系列模型^{⑥⑦}。GPT-3 模型包含了前所未有的 1750 亿个参数,并以其强大的生成能力和 Few-shot 样本学习能力开启了大语言模型时代^⑧。

2023 年,随着硬件计算能力的提升,大语言模型已基本适用于自然语言处理领域,在所有自然语言处理任务中获得较以往更高的性能。这使大规模预训练语言模型甚至在整个人工智能领域成为一种可能的通用解决方案。在 GPT-4 模型发布后,其对话能力、文本生成能力、数学推理能力以及多模态信息处理能力的集中体现引发人工智能领域研究者对大模型通向泛人工智能话题的讨论。

换言之,自然语言处理领域在过去几年发生了显著变化。尤其在深度学习技术大范围应用后使 NLP 领域在文本理解和文本生成方面取得了前所未有的成就。以上技术和发展为自然语言处理在各种实际中的应用奠定了基础。

(二) 自然语言处理的应用

1. 机器翻译

机器翻译 (MT) 是自然语言处理的典型应用。它涉及使用数学和算法技术将一种语言文档翻译成另一种语言文档。即使对于人类而言,有效的翻译本质上也较为困难,需要在形态、句法和语义等方面具备熟练的能力以及对所考虑的两语言文化(社会)敏感性具有熟练的理解和判断能力。

- ① Vaswani, A., Shazeer, N., Parmar, N., et al. Attention is all you need, Advances in Neural Information Processing Systems, 2017: 5998-6008.
- ② Dai, Z., Yang, Z., Yang, Y., et al. Transformer-xl: Attentive language models beyond a fixed-length context, arXiv preprint arXiv: 1901.02860, 2019.
- ③ Rae, J.W., Potapenko, A., Jayakumar, S.M., et al. Compressive transformers for long-range sequence modelling, arXiv preprint arXiv: 1911.05507, 2019.
- ④ Otter, D.W., Medina, J.R., Kalita, J.K. A survey of the usages of deep learning for natural language processing, IEEE Transactions on Neural Networks and Learning Systems, 2020(2): 604-624.
- ⑤ Devlin, J., Chang, M.W., Lee, K., et al. Bert: Pre-training of deep bidirectional transformers for language understanding, arXiv preprint arXiv: 1810.04805, 2018.
- ⑥ Radford, A., Narasimhan, K., Salimans, T., et al. Improving language understanding by generative pre-training, 2018.
- ⑦ Radford, A., Wu, J., Child, R., et al. Language models are unsupervised multitask learners, OpenAI blog, 2019(8): 9.
- ⑧ Brown, T., Mann, B., Ryder, N., et al. Language models are few-shot learners, Advances in neural information processing systems, 2020: 1877-1901.

神经机器翻译(NMT)的第一次尝试由Schwenk^①提出,尽管神经模型之前已被用于类似的转写任务,将文本的某些部分(例如,专有名词)转换成不同的语言。Schwenk使用具有7个词的输入和输出的前馈网络,在必要时进行填充和修剪。

从一个长句子翻译为另一个长句子的能力随着编码器—解码器模型的引入而出现。该模型由Kalchbrenner和Blumson提出,源于连续循环表示在捕捉语法、语义和形态方面的成功以及RNN构建强健语言模型的能力^②。这一最初的NMT编码器—解码器模型使用一种生成卷积和循环层的组合编码及优化源语言模型,将其转化为目标语言。该模型很快被Cho等重新设计和进一步研究,并对该模型诸多新颖和有效的改进进行了研究^③。编码器—解码器模型不断提升之前翻译的性能,扩展到包含数十个层,具有残差连接、注意力机制,甚至是允许最终解码层关注第一个编码层的残差注意力机制。同时,在编码器和解码器中使用大量卷积层,允许信息在几个层次结构中被查看,而不是通过多个循环步骤,取得最新的技术水平结果。这样的衍生模型不断改进,找到了之前的缺点并克服了任何需要手工工程的需求。该研究的进展还包括解码器隐藏状态的有效初始化、条件门控注意力单元的使用、嵌入层中消除偏差、使用替代解码阶段方法,嵌入的因式分解以及测试时间使用束搜索算法。解码器状态的标准初始化由Bahdanau等提出,使用最后一个向后编码器状态。然而,如Britz等所言,使用神经网络输出表征的平均值似乎会产生最佳翻译。门控循环单元已成为序列到序列任务的标准,其中的一种变体是条件GRU(cGRU),能最有效地与注意力机制配合使用。cGRU单元由三

个关键组件组成:两个GRU转换块和它们之间的注意力机制。这三个块结合先前的隐藏状态以及注意力上下文窗口,生成下一个隐藏状态。将解码过程从查看输入、生成输出、更新隐藏表示的过程改为查看、更新、生成的过程可简化最终的解码过程。为添加更多的源端翻译内容的属性,例如,POS标签和句法依赖标签,可改善翻译模型性能,并且可进一步提高鲁棒性。为记忆长期的依赖关系,垂直堆叠的循环单元已成为标准,最佳层数的确定大概在2—6层,取决于所需的输入长度以及残差连接的存在和密度。在测试时,可在最终的Softmax层旁边使用束搜索算法,以贪婪方式考虑多个目标预测,允许找到最佳的预测而不需要查看整个假设空间。

与以往的工作方向不同,Vaswani等提出放弃大量的循环和卷积层,专注于使用注意力机制从输入到输出全局编码语言^④。他们选择自注意力机制有三个原则:减少每层所需的计算复杂性、最小化连续的训练步骤和减少从输入到输出的路径长度及其对学习长期依赖关系的影响,上述原则在许多序列到序列的生成任务中是必要的。除在翻译任务中提高准确性外,自注意力模型允许在整个体系结构中进行更多的并行处理,减少训练时间并最小化必要的连续步骤。例如,2014年,在国际口语翻译研讨会(IWSLT)测试语料库中的英德和英法翻译任务,生成最佳结果的最新模型是Medina和Kalita^⑤的模型,他们修改了Vaswani提出的模型,使用并行自注意力机制。除提高BLE分数外,还减少了自注意力机制的训练时间。Ghazvininejad等将BERT应用于机器翻译任务,能在更少时间内达到与基线模型竞争的表现^⑥。Lample等使用多种语言在其语言模型预训练中进行无监督机器翻译,

① Schwenk, H. Continuous space translation models for phrase-based statistical machine translation, COLING, 2012: 1071-1080.

② Kalchbrenner, N., Blumson, P. Recurrent continuous translation models, EMNLP, 2013: 1700-1709.

③ Cho, K., Van Merriënboer B., Gulcehre, C., et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation, rXiv preprint arXiv: 1406.1078, 2014.

④ Vaswani, A., Shazeer, N., Parmar, N., et al. Attention is all you need, Advances in Neural Information Processing Systems, 2017: 5998-6008.

⑤ Medina, J.R., Kalita, J. Parallel attention mechanisms in neural machine translation, arXiv preprint arXiv: 1810.12427, 2018.

⑥ Ghazvininejad, M., Levy, O., Liu, Y., et al. Constant-time machine translation with conditional masked language models, arXiv preprint arXiv: 1904.09324, 2019.

实现了最优结果^①。Chen 等检查并拆分了最先进的部分模型，确定哪些特征真正负责其强大性，从而提供了公平比较^②。他们使用这些知识创建了混合模型，并整合之前每个模型的最佳部分，最终超越了前期模型。Denkowski 等检查了其他提升翻译性能的技术，并推荐了三项技术：使用 Adam 优化、多次重启以及进行学习率退火；执行字词翻译；使用多个解码器的集合^③。他们发现，数据增强（使用训练示例中的短语作为额外的独立较小样本）即使对已经表现良好的模型也有益，因此，建议未来发展在表现最好的模型上进行测试，以确定其有效范围。

除以上呈现的研究外，还有一项研究列出了该领域面临诸多挑战^④。虽然神经机器翻译模型优于其他形式的统计机器翻译模型（以及基于规则的模型），但其需要更多数据，并且在其训练的领域外表现不佳，无法充分处理罕见词语，同时，在处理长句（超过约 60 个单词）方面效果不佳。此外，注意力机制在对齐单词方面不及统计机器翻译，且用于解码的束搜索仅在搜索空间较小时才有效。上述缺点是未来研究的重点。值得注意的是，研究包括使用缓存为网络提供比仅翻译单个句子更多的上下文^⑤，更好处理罕见词语以及能翻译被忽视的语言，例如，多合成语言。此外，对超参数的选择、敏感性和调整、数据去噪和围绕神经机器翻译的许多其他重要主题的工作也在进行。机器翻译的另一个重要方向是多语言翻译。近期研究表明，可以训练单一、简单的（大型的）神经网络将多个语言

（至少达到 12 种）互相转换，自动识别源语言并仅需一个输入标记识别输出语言^⑥。此外，研究发现该模型能在某种程度理解多语言输入，并在给出多个语言标记时产生混合输出，有时甚至是与所选语言相关但实际不是那些语言的混合输出。这表明深度神经网络可能能够学习信息的通用表示而与语言无关，甚至可能是学习一些不同语言家族之间的词源和关系。

随着大规模语言模型的出现，翻译任务使用大规模语言模型进行多语言机器翻译越来越受到关注。Lin 等对 182 个方向上的 GPT-3 和 XGLM-7.5B 进行评估^⑦。Bang 等对 12 个方向上的 ChatGPT 进行评估^⑧。其中，通过机器翻译上下文学习（In-Context Learning, ICL）的方法效果在上述工作中得到验证，因此，对如何寻找一个合适的上下文学习方法，当前阶段已投入许多努力设计示例选择策略。此外，Vilar 等发现使用高质量的样本池（例如，开发集）进行 ICL 示例选择更好^⑨，并且 Zhang 等分析了翻译示例质量的重要性。

总之，机器翻译是一项典型的自然语言处理应用，通过数学和算法技术将一种语言的文档翻译为另一种语言。研究者一直努力改进机器翻译的性能，自注意力模型在机器翻译中取得了重要突破。相较于传统的循环和卷积层，自注意力模型在提高翻译准确性的同时减少了计算的复杂性，实现了更高效的训练和推理。此外，研究者关注处理长句和罕见词语的挑战。这些问题对实现更准确和鲁棒的翻译至关重要。未来的研究可能集中在改进注意力

① Lample, G., Conneau, A. Cross-lingual language model pretraining, arXiv preprint arXiv: 1901.07291, 2019.

② Chen, M.X., Firat, O., Bapna, A., et al. The best of both worlds: Combining recent advances in neural machine translation, arXiv preprint arXiv: 1804.09849, 2018.

③ Denkowski, M., Neubig, G. (2017) Stronger baselines for trustable results in neural machine translation, arXiv preprint arXiv: 1706.09733.

④ Koehn, P., Knowles, R. (2017) Six challenges for neural machine translation, arXiv preprint arXiv: 1706.03872.

⑤ Kuang, S., Xiong, D., Luo, W., et al. (2018) Modeling coherence for neural machine translation with dynamic and topic caches, In COLING 2018: Proceedings of the 27th International Conference on Computational Linguistics: Technical Papers, pp. 596-606.

⑥ Johnson, M., Schuster, M., Le, Q.V., et al. (2016) Google's multilingual neural machine translation system: Enabling zero-shot translation, arXiv preprint arXiv: 1611.04558.

⑦ Lin, X. V., Mihaylov, T., Artetxe, M., et al. Few-shot learning with multilingual language models, arXiv preprint arXiv: 2112.10668, 2021.

⑧ Bang, Y., Cahyawijaya, S., Lee, N., et al. A multitask, multilingual, multimodal evaluation of chatgpt on reasoning, hallucination, and interactivity, arXiv preprint arXiv: 2302.04023, 2023.

⑨ Vilar, D., Freitag, M., Cherry, C., et al. Prompting PaLM for Translation: Assessing Strategies and Performance, arXiv preprint arXiv: 2211.09102, 2022.

机制、优化解码过程以及处理多语言翻译等方面,以进一步提高机器翻译的性能和适用性。此外,大规模语言模型在机器翻译中的应用越来越受到关注。研究者通过评估不同模型在多语言翻译任务中的表现,探索如何利用上下文学习方法提升机器翻译的效果。通过对示例选择策略和翻译示例质量等方面的研究,有望进一步提高机器翻译的质量和可靠性。因此,机器翻译领域的发展不断取得突破,并在实现更准确、高效和多样化的翻译方面展现出巨大潜力。随着进一步的研究和技术创新,机器翻译有望在跨语言交流和文化交流方面发挥越来越重要的作用。

2. 文本摘要

摘要任务旨在总结文档的关键要素,生成对最重要内容的概述。摘要主要分为两类:抽取式和生成式。抽取式摘要关注从文档中直接提取文本,简化句子并重新排序和连接,以便传达文档的重要信息。生成式摘要依赖生成式概括表达文档内容,可能采用文档中未出现过的词汇。

Rush 等将深度学习引入摘要领域,利用前馈神经网络构建了一个编码器与生成式束搜索解码器的语言模型^①。相较于当时其他先进的方法,该模型具有可比的性能。注意力机制进一步提高了编码器—解码器模型的表现。有的研究方法采用多重时序注意力编码器机制,关注解码器在先前生成单词上的输出标记。采用类似 Ranzato 等提出的混合交叉熵损失函数,可将训练和执行时间减少数个数量级^②。因此,建议采用强化学习领域的策略调整梯

度并降低曝光偏差。

Zhang 等提出一种基于 BERT 编码器的编码器—解码器框架,用于生成输出序列^③。解码器分为两个阶段:第一阶段利用基于 Transformer 的解码器生成草稿输出序列;第二阶段对草稿序列中的每个单词进行掩蔽处理,并将其输入 BERT 编码器进行优化。该模型在 CNN / Daily Mail 和 New York Times 数据集上实现了最先进的性能。

有几项研究使用预训练模型进行抽象文本摘要。Farahani 等使用 mT5 和序列到序列的 ParsBERT 构建波斯文本的抽象摘要^④。Kieu-vongngam 等^⑤使用 BERT 和 GPT-2 对 COVID-19 生物医学研究文章进行摘要。文档特征被提取并整合到抽象模型中以提高摘要生成效果。Nambiar 等开发了一个使用注意力的编码器—解码器模型,将词性特征合并到词向量层中以增强词向量^⑥。在马拉雅拉姆语数据集上的实验表明,注意力模型和词性特征的整合效果优于 Seq2seq 和注意力模型。Barna 和 Heickal 通过结合预训练的词嵌入层和主题特征改进指针生成器网络的抽象摘要^⑦。通常,抽象摘要的一个缺点是忽略了命名实体。为改善这一缺点,Berezin 和 Batura 训练了一个基于 ROBERTa 的命名实体识别模型发现命名实体^⑧。进而训练 BART 遮蔽命名实体语言模型关注命名实体。最后,对 BART 进行微调以进行文本摘要。

总之,摘要任务主要分为抽取式和生成式两类,前者从文档中提取关键信息,后者通过生成式概括表达文档内容。深度学习和注意力机制的引入

① Rush, A.M., Chopra, S., Weston, J. (2015) A neural attention model for abstractive sentence summarization, arXiv preprint arXiv: 1509.00685.

② Ranzato, M., Chopra, S., Auli, M., et al. Sequence level training with recurrent neural networks, arXiv preprint arXiv: 1511.06732, 2015.

③ Zhang, H., Gong, Y., Yan, Y., et al. Pretraining-based natural language generation for text summarization, arXiv preprint arXiv: 1902.09243, 2019.

④ Farahani, M., Gharachorloo, M., Manthouri, M. Leveraging ParsBERT and pretrained mT5 for Persian abstractive text summarization, 2021 26th International Computer Conference, Computer Society of Iran (CSICC). IEEE, 2021: 1-6.

⑤ Kieu-vongngam, V., Tan, B., Niu, Y. Automatic text summarization of covid-19 medical research articles using bert and gpt-2, arXiv preprint arXiv: 2006.01997, 2020.

⑥ K. Nambiar S, Peter S D, Mary Idicula S. Abstractive Summarization of Text Document in Malayalam Language: Enhancing Attention Model Using POS Tagging Feature, ACM Transactions on Asian and Low-Resource Language Information Processing, 2023 (2): 1-14.

⑦ Barna, N. H., Heickal, H. An Automatic Abstractive Text Summarization System, Dhaka University Journal of Applied Science and Engineering, 2021 (2): 39-48.

⑧ Berezin, S., Batura, T. Named Entity Inclusion in Abstractive Text Summarization, Proceedings of the Third, Workshop on Scholarly Document Processing, 2022: 158-162.

提高了摘要模型的性能和表现。使用预训练模型如 BERT、mT5 和 GPT-2 等进行抽象文本摘要会取得良好效果。部分研究结合文档特征、词性特征和命名实体识别等方法进一步提升摘要生成效果。改进抽象摘要的一个关键问题是如何处理命名实体，部分研究通过训练专门的模型关注和识别命名实体，进行微调以生成更准确的摘要。

3. 问答与对话系统

问答系统 (QA) 与摘要和信息提取相似，从文档中搜集相关词汇、短语或句子，以连贯方式回应请求并返回这些信息。现行方法与摘要方法具有相似性。

Wang 等利用门控注意力循环网络将问题与含有答案的段落进行匹配^①。通过映射整个段落，自我匹配注意力机制可改善机器表示。同时，采用指针网络预测答案的位置和边界。这些网络利用注意力机制汇聚段落的向量表示以及正在分析的单词，从而建模必要的标记或短语。

Dong 等使用多列 CNN 自动处理多个视角的问题，并行网络被用于从输入问题中提取关联信息^②。通过使用单独的网络寻找上下文信息和关系，确定应返回哪种形式的答案。这些网络的输出被组合并用于对潜在答案进行排序。

Santoro 等^③采用关系网络 (RNs) 进行摘要，RNs 基于 MLP 架构构建，专注于关系推理，即确定数据中实体之间的关系。这些前馈网络在所有对象之间实现类似功能，以汇聚它们之间的相关性。在输入方面，RNs 使用文档句子的最终 LSTM 表示。这些输入进一步与给定信息请求的表示进行配对。

在 SQuAD 1.1 和 SQuAD2.0 数据集上的 QA 实验中，BERT 达到了更好的水平。Yang 等展示

了一种将 BERT 与开源 Anserini 信息检索工具包集成的端到端问答系统^④。该系统能够以端到端的方式从大量维基百科文章中识别答案，并在标准基准测试集上获得最佳结果。此类研究为问答系统的发展提供了新的方法和实践，不断优化模型性能和效果。

在当前的大规模语言模型阶段，闭卷问答任务以及开卷问答任务是测试大规模语言模型对预训练语料库获取的事实知识的理解能力的两种主要形式。在闭卷问答中，大规模语言模型要仅基于给定的上下文回答问题，不能使用任何外部资源。自然问题 (Natural Questions)、网络问题 (Web Questions) 和 TriviaQA 等数据集是评估此能力的工具，其中，准确率是一个广泛使用的指标。大规模语言模型在这一设置中表现优秀，可与最先进的开放领域问答系统的性能相匹配。需要注意的是，即使在预训练数据中存在细粒度知识，大规模语言模型在依赖细粒度知识的问答任务上的表现可能不如预期^⑤。

此外，开卷问答任务允许大规模语言模型从外部知识库或文档集合中提取信息，随后基于提取的证据回答问题。开放式书本问答 (OpenBookQA) 和 SQuAD 等数据集进行开卷问答任务，这些数据集通常会结合外部数据源，例如，维基百科。为从这些资源中选择相关知识，大规模语言模型通常与文本检索器或搜索引擎配合使用，这些检索工具可以独立或与大规模语言模型联合训练^⑥。实证结果显示，使用提取的证据可以提高答案的准确性，甚至使较小的模型优于大 10 倍的模型。无论是闭卷问答任务还是开卷问答任务，都证明了大规模语言模型有能力从预训练数据中学习 (或记忆) 更多知识，模型和数据的规模扩展性将提高其性能。在相

① Wang, W., Yang, N., Wei, F., et al. Gated self-matching networks for reading comprehension and question answering ACL. 2017, vol. 1 : 189-198.

② Dong, L., Wei, F., Zhou, M., et al. Question answering over freebase with multi-column convolutional neural networks, ACL and International Joint Conf on NLP. 2015 : 260-269.

③ Santoro, A., Raposo, D., Barrett, D.G., et al. A simple neural network module for relational reasoning, NIPS, 2017 : 4974-4983.

④ Yang, W., Xie, Y., Lin, A., et al. End-to-end open-domain question answering with bertserini, arXiv preprint arXiv: 1902.01718, 2019.

⑤ Brown, T., Mann, B., Ryder, N., et al. Language models are few-shot learners, Advances in neural information processing systems, 2020 : 1877-1901.

⑥ Nakano, R., Hilton, J., Balaji, S., et al. Webgpt: Browser-assisted question-answering with human feedback, arXiv preprint arXiv: 2112.09332, 2021.

同的参数规模下,拥有更多与评估任务相关预训练数据的大规模语言模型将表现的更好^①。然而,从过时的知识资源进行预训练或检索,可能导致大规模语言模型在回答时间敏感问题时产生错误答案。

上述研究显示,问答系统的优化与发展越来越依赖深度学习技术和大规模语言模型,特别是在处理大量预训练数据,理解复杂上下文关系和提取关键信息方面。但也存在挑战,例如,大规模语言模型在处理细粒度知识和时间敏感问题方面的局限性,需进一步研究和改进。同时,这暗示了尚未被充分开发的机会,例如,如何更好地结合闭卷和开卷问答任务的优势以及如何更有效地结合外部知识库和文档集合以提高问答的准确性。

对话任务可以理解作为一种更加困难的问答任务,不仅要求对用户输入一次的文本进行回答,而且要在多轮对话中解决更复杂的任务。因此,开发拥有长期记忆、生成引人入胜且连贯的回复,并在各种对话任务中表现出色的开放域聊天机器人系统是一个长期存在的挑战。为应对对话建模的特定属性,提出几种 Seq2Seq 模型。目前,人们对预训练大型对话生成模型的关注度较高,例如,DialogPT、Plato、Blenderbot 和 Meena,皆使用 Transformer 架构。检索增强生成(Retrieval Augmented Generation, RAG)是解决大型和小型模型的对话生成任务的另一种突出方法。尽管像 175B 的 Blenderbot-3 或 137B 的 LaMDA 此类大规模预训练模型在多个对话数据集上都能获得高准确性,但由于模型尺寸不断增大,这些方法可能会产生昂贵的代价。大模型的规模使微调变得困难,但基于提示的模型中,上下文学习机制使微调变得不

必要。

4. 信息抽取

信息提取是从文本中提取显式或隐式信息。系统的输出有所不同,但通常提取的数据和其中的关系保存在关系型数据库中^②。常见的提取信息包括命名实体和关系、事件及其参与者、时间信息和事实元组。

命名实体识别(NER)指识别专有名词及诸如日期、时间、价格和产品 ID 等信息。Collobert 等^③的多任务方法中包括该任务,但没有报告结果。在这一方法中,使用了一个简单的前馈网络,其上下文具有固定大小的窗口,围绕每个单词,这可能使其难以捕捉单词之间的长距离关系。Hammerton 首次将 LSTMs 用于 NER^④。由于当时缺乏可用的计算能力,该模型规模较小。此外,单词的复杂数值向量模型尚不可用。结果对于英语略优于基准线,对于德语比基准线更好。Dos Santos 等使用一种被称为 CharWNN 的深度神经网络架构,该架构同时使用了单词级别和字符级别的输入执行顺序分类^⑤。在这项研究中,使用了 HAREMI 注释的葡萄牙语语料库^⑥和 SPA CoNLL2002 注释的西班牙语语料库^⑦进行了许多实验。对于葡萄牙语语料库,CharWNN 在 10 个命名实体类中均优于此前的最先进系统,它在西班牙语中也达到了最先进的性能。笔者认为,单独使用单词嵌入或字符级别嵌入都无效。这再次验证了长期以来已知的一个事实:联合使用单词级别和字符级别的特征对有效的 NER 性能很重要。Chiu 和 Nichols 使用双向 LSTM 和字符级 CNN 的模型,并未使用任何私人词典,最终在 CoNLL-2003 和 OntoNotes 数据集上取得最先进

- ① Nakano, R., Hilton, J., Balaji, S., et al. Webgpt: Browser-assisted question-answering with human feedback, arXiv preprint arXiv: 2112.09332, 2021.
- ② Cowie, J., Lehnert, W. Information extraction, Communications of the ACM, 1996(1): 80-91.
- ③ Collobert, R., Weston, J., Bottou, L., et al. Natural language processing (almost) from scratch, Journal of Machine Learning Research, 2011: 2493-2537.
- ④ Hammerton, J. Named entity recognition with long short-term memory, Proceedings of the seventh conference on Natural language learning at HLT-NAACL 2003, 2003: 172-175.
- ⑤ Dos Santos C., Guimarães, V. Boosting Named Entity Recognition with Neural Character Embeddings, Proceedings of the Fifth Named Entity Workshop, 2015: 25-33.
- ⑥ Santos, D., Seco, N., Cardoso, N., et al. Harem: An advanced ner evaluation contest for portuguese, In Nicoletta Calzolari; Khalid Choukri; Aldo Gangemi; Bente Maegaard; Joseph Mariani; Jan Odjik; Daniel Tapias (ed) Proceedings of the 5th International Conference on Language Resources and Evaluation (LREC'2006) (Genoa Italy 22-28 May 2006), 2006.
- ⑦ Carreras, X., Marquez, L., Padró, L. Named entity extraction using adaboost, COLING-02: The 6th Conference on Natural Language Learning 2002 (CoNLL-2002), 2002.

的结果^①。Lample等开发了一种基于双向LSTMs和条件随机场(CRF)的架构^②。该模型使用字符级别和单词嵌入。这些输入被组合后送入一个双向LSTM,其输出又被馈送到执行CRF计算的层^③。在使用Dropout进行训练时,该模型在德语和西班牙语方面都达到了最先进的性能。LSTM-CRF模型在英语和荷兰语方面较接近最先进水平。该研究表明,在不使用任何手工特征或词表的情况下,已实现最先进的结果。Akbik等使用预训练的双向字符语言模型,在德语和英语NER方面实现了最先进的性能^④。他们为每个单词检索上下文嵌入,将其传递到BiLSTM-CRF序列标注器中进行NER。

事件提取涉及识别指向事件发生的词或短语以及参与者,例如,代理人、对象、接收者和发生时间。事件提取通常涉及四个子任务:识别事件提及或描述事件的短语;识别事件触发器,即指定事件发生的主要词语,通常是动词或动名词;识别事件的参数;识别参数在事件中的角色。Chen等认为,使用最大池化CNN很可能只捕捉到句子中最重要的信息^⑤,因此,在考虑涉及多个事件的句子时,可能会错过有价值的事实。为解决这一问题,他们将特征映射分为三部分,保留每一部分的最大值。在第一部分,他们将每个单词分类为触发词或非触发词。如果找到触发器,第二部分将对参数的角色

进行对齐。结果表明,这种方法显著优于当时其他最先进的方法。2016年,Nguyen等使用基于RNN的编码器—解码器方法识别事件触发器和角色,超过了早期的结果^⑥。Liu等提出一种潜在变量神经模型诱导事件模式并提取开放领域的事件,在他们创建和发布的数据集上取得了最佳结果^⑦。

关系提取是从文本中提取的关系信息。这些关系可能是所有格、反义词或同义词关系,也可能是更自然的家庭或地理关系。第一个深度学习方法是Zheng等使用简单的CNN分类句子中元素之间的多种关系^⑧。使用仅两层、大小为三的窗口和仅有50个维度的单词嵌入,取得了较先前任何方法都好的结果。他们进一步研究了使用双向LSTM和CNN进行关系分类以及实体识别的工作。Sun等使用基于注意力的GRU模型和复制机制^⑨。该网络的新颖之处在于使用了被称为“覆盖机制”的数据结构,其有助于确保提取所有重要信息的正确次数。Lin等使用预训练的BERT模型和生物医学数据集上的监督训练,在临床时间关系提取方面实现了最先进的性能^⑩。

5. 文本分类

自然语言处理领域的一个重要应用是文本分类,即将非结构化文本文档归类到预先定义类别中,这一任务具有广泛的实际应用。Kim首次在

- ① Chiu, J. P. C., Nichols, E. Named entity recognition with bidirectional LSTM-CNNs, Transactions of the association for computational linguistics, 2016 : 357-370.
- ② Lample, G., Ballesteros, M., Subramanian, S., et al. Neural Architectures for Named Entity Recognition, Proceedings of NAACL-HLT, 2016 : 260-270.
- ③ Lafferty, J., McCallum, A., Pereira, F. C. N. Conditional random fields: Probabilistic models for segmenting and labeling sequence data, 2001.
- ④ Akbik, A., Blythe, D., Vollgraf, R. Contextual string embeddings for sequence labeling, Proceedings of the 27th international conference on computational linguistics, 2018 : 1638-1649.
- ⑤ Chen, Y., Xu, L., Liu, K., et al. Event extraction via dynamic multi-pooling convolutional neural networks, ACL. 2015 : 167-176.
- ⑥ Nguyen, T.H., Cho, K., Grishman, R. Joint event extraction via recurrent neural networks, Conf of the North American Chapter of ACL: Human Language Technologies, 2016 : 300-309.
- ⑦ Liu, X., Huang, H., Zhang, Y. Open domain event extraction using neural latent variable models, arXiv preprint arXiv: 1906.06947, 2019.
- ⑧ Zheng, S., Hao, Y., Lu, D., et al. Joint entity and relation extraction based on a hybrid neural network, Neurocomputing, 2017 : 59-66.
- ⑨ Sun, M., Li, X., Wang, X., et al. Logician: A unified end-to-end neural approach for open-domain information extraction, ACM Intl Conf on Web Search and Data Mining, 2018.
- ⑩ Lin, C., Miller, T., Dligach, D., et al. A bert-based universal model for both within-and cross-sentence clinical temporal relation extraction, Clinical NLP Workshop, 2019 : 65-71.

卷积神经网络 (CNN) 中应用预训练词向量进行句子级别分类^①。他的工作激发了后续研究,并证明了一个简单的 CNN,在仅用一个卷积层后跟随一个包含 Dropout 和 Softmax 输出的全连接层,只需少量超参数调整就能在多个基准测试上实现良好结果。其提出的 CNN 模型在包括情感分析和问题分类在内的 7 个任务中的 4 个任务上优于现有技术。Conneau 等证实了具有多个卷积层的网络在文档分类任务上表现出色^②。Jiang 等提出一种结合深度置信网络和 Softmax 回归的混合架构^③。深度置信网络是一种前馈网络,其隐藏层成对地设计为类似于受限玻尔兹曼机的结构,采用无监督学习进行训练,旨在增加或减少数据维度。通过多次向前和向后传播数据,寻找基于能量的最小损失实现。这一过程与任务的标签或分类部分无关,因此,在没有 Softmax 回归输出层的情况下进行了预训练。一旦两个部分的架构都经过预训练,它们将被组合,像常规深度神经网络一样使用反向传播和拟牛顿方法进行训练。Adhikari 等利用 BERT 在四个文档数据集上进一步提升了文本分类的结果^④。尽管深度学习在包括文本分类在内的许多 NLP 领域具有广泛潜力,但它并非所有问题的终极解决方案,仍存在许多挑战。Worsham 和 Kalita 发现,在将长篇小说按类型分类的任务中,梯度提升决策树方法胜过经典的神经网络方法(包括 CNN 和 LSTM)^⑤。

(三) 大语言模型

1. 语言模型发展概述

近年来,自然语言领域较受关注的研究即大语言模型,它的出现为自然语言处理提供了新的研究范式。生成式语言模型的研究早在 20 世纪中叶就已开始,直到目前,随着显卡算力的提升,模型参数量的大幅提升才成为可能。

语言模型(Language Model)旨在建模词汇序列的生成概率,提升机器的语言智能水平,使机器能够模拟人类说话、写作的模式进行自动文本输出。按照 Zhao 等的观点^⑥,语言模型技术的发展可以总结为四个阶段:基于规则和统计的语言模型、神经语言模型、预训练语言模型和大语言模型。在第一阶段,人们设计人工特征并使用统计方法对固定长度的文本窗口序列进行建模分析,这种建模方式也被称为 N-gram 语言模型。但当分析序列长度增加时,这种分析手段的复杂度随之上升。随着神经网络的兴起,人们逐渐开始使用能处理序列的网络结构(例如,循环神经网络 RNN)建模词汇序列的生成概率,诞生了 Word2vec、ELMo 等一批语义表征方法。但当时的神经网络架构对长序列的建模能力有限,可能会出现长距离遗忘以及训练时的梯度消失等问题,构建的模型难以进行稳定的长文本输出。2017 年,随着 Transformer 网络架构的提出,极大程度地缓解了长文本序列遗忘问题,人们开始关注语言模型在大范围文本上训练的可能性。第三阶段诞生了诸多基于 Transformer 架构的预训练语言模型,例如, BERT、BART、GPT,等等。实验结果证明,这些模型在大量文本序列上进行语言模型建模训练后,只需在具体下游语言任务(例如,文本分类、文本问答,等等)上进行微调即可获得超越以往所有方法的性能。此后,预训练+微调的语言模型学习范式改变了自然语言处理领域的研究方法。人们开始关注预训练过程以及微调过程的优化,并将统一的预训练模型通过不同的微调策略和微调数据应用到广泛的领域任务中。

随着对预训练语言模型研究的开展,人们逐渐发现可能存在一种标度定律(Scaling Law),即随着预训练模型参数的指数级提升,其语言模型

① Kim, Y. Convolutional Neural Networks for Sentence Classification, Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014: 1746-1751.

② Conneau, A., Schwenk, H., Barrault, L., et al. (2017) Very deep convolutional networks for text classification. In Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers (pp. 1107-1116).

③ Jiang, M., Liang, Y., Feng, X., et al. (2018) Text classification based on deep belief network and softmax regression. Neural Computing and Applications, 29(1): 61-70.

④ Adhikari, A., Ram, A., Tang, R., et al. (2019) Docbert: Bert for document classification, arXiv preprint arXiv: 1904.08398.

⑤ Worsham, J., Kalita, J. (2018) Genre identification and the compositional effect of genre in literature, In Proceedings of the 27th International Conference on Computational Linguistics (pp. 1963-1973).

⑥ Zhao, W. X., Zhou, K., Li, J., et al. A survey of large language models, arXiv preprint arXiv: 2303.18223, 2023.

性能也会线性上升。2020 年, OpenAI 发布了参数量高达 1750 亿的 GPT-3, 首次展示了大语言模型的性能。相较于此前的参数量较小的预训练语言模型, 例如, 3.3 亿参数的 Bert-large 和 17 亿参数的 GPT-2, GPT-3 展现了在 Few-shot 语言任务能力上的飞跃, 并具备了预训练语言模型不具备的一些能力。在后续研究中, Wei 等将这种现象称为能力涌现^①。例如, GPT-3 能进行上下文学习, 在不调整权重的情况下仅依据用户给出的任务示例完成后续任务。这种能力方面的飞跃引发研究界在大语言模型上的研究热潮, 各大科技巨头纷纷推出参数量巨大的语言模型, 例如, Meta 公司 1300 亿参数量的 LLaMA 模型^②以及谷歌公司 5400 亿参数量的 PaLM。国内如百度推出的文心一言 ERNIE 系列、清华大学团队推出的 GLM 系列, 等等。在语言模型技术发展的第四阶段, 大语言模型不仅影响了自然语言处理领域, 而且对整个人工智能领域产生了巨大冲击。里程碑式的 ChatGPT 具备了能与人类沟通聊天的能力, 甚至具备了使用插件进行自动信息检索的能力。GPT-4 能进行多模态信息处理^③, 并且具备惊人的逻辑推理能力。从 CLIP 开始引入的多模态大模型带动计算机视觉领域开始探寻视觉大模型的可能。

大语言模型为自然语言处理领域带来了新的机遇, 但当前大语言模型的研究仍存在一些亟待解决的关键问题。首先, 研究界目前仍缺乏对大语言模型的能力涌现原因的量化分析, 这使人们暂时无法掌握合理有效的方式促进模型的性能提升。其次, 由于大语言模型对算力提出了较高要求, 因此, 目前占据大语言模型研究前沿的都是科技龙头企业, 学术界囿于资源水平无法参与最新的研究。值得关注的是, 由于大语言模型能快速转变为高端人工智能产品变现, 其商业价值使多数大语言模型处于闭源或半开源的状态。但学术界仍致力于在开源的学术氛围中讨论大语言模型在关键技术上的改进。

2. 大语言模型架构

相较于传统的 LSTM 等序列处理网络, Transformer 的长序列处理能力大幅提升。目前, 大语言模型基本采用 Transformer 网络架构作为基

础进行修改。Transformer 原本架构由编码器—解码器组成, 运用于大语言模型中的架构经过调整主要可以总结为编码器—解码器、仅解码器两种。

由于 Open AI 的 GPT 系列的出众能力, 当前多数大语言模型基于仅解码器 (Decoder-only) 架构进行设计。这种架构的网络在计算序列上特定位置 Token 的注意力时, 只会与位于该位置前的 Token 进行计算, 不会考虑后续 Token。这种方式部分源自 GPT 系列选择的语言模型建模方式, 即从上文生成下一个 Token 模式。GPT-3 模型的成功证明了这种架构的有效性, 后续的 BLOOM、OPT 等模型均采用这种架构。当然, 也有部分大模型在解码器架构上进行改进, 在进行注意力机制计算时考虑部分下文, 例如, 清华大学的 GLM-130B 以及谷歌的 U-PaLM 都属于这种架构。这种架构也被称作前缀解码器 (Prefix Decoder) 架构。

同时, 直接沿用 Transformer 原本架构的大语言模型得到研究界的关注, 例如, mT5, 等等。在这一架构中, 编码器采用堆叠的多头自注意层对输入序列进行编码, 以生成其潜在表示。解码器对这些表示进行交叉注意计算, 并用自回归的方式逐个 Token 生成目标序列。

3. 大语言模型并行训练

由于大语言模型的模型参数量巨大, 训练大语言模型成为一项有挑战的任务。例如, 70 亿参数版本的 LLaMA 模型在使用训练优化器 Adam 进行训练时至少需要占用 110G 以上的显存, 但目前并没有满足这一显存需求的单张计算显卡。受限于当前专业计算显卡显存限制, 规模较大的模型必须使用并行策略才能进行有效的训练和微调。

为此一些并行框架应运而生, 目前主流的 Deepspeed 以及 Megatron-LM 等实现了张量并行算法。在这些框架中, 模型训练过程中每个网络层不必计算全量的输入, 而只关注输入的一部分获得其输出即可。当每个并行任务处理各自的输入部分计算后, 全部计算结果将通过通信手段合并, 实现与单卡状态一样的计算结果。当然, 节省显存的方法不止这一种, 常用的还有混合精度训练等措施。

① Wei, J., Tay, Y., Bommasani, R., et al. Emergent Abilities of Large Language Models, Transactions on Machine Learning Research, 2022.

② Touvron, H., Lavril, T., Izacard, G., et al. Llama: Open and efficient foundation language models, arXiv preprint arXiv: 2302.13971, 2023.

③ Open AI. GPT-4 Technical Report, rXiv: 2303.08774, 2023.

4. 大语言模型微调

由于大语言模型尝试从训练语料库中提取并压缩语言信息,从而实现对语言模型的建模过程。目前,大语言模型使用的语料库通常体量庞大,无法进行人工精细筛选,因此,大语言模型在生成过程中不可避免地会从训练语料库中模仿并生成部分有害的、有偏见的内容。同时,大语言模型在一般的网络文本或书籍文本中进行训练后通常并不能较好地服从用户的指示。解决上述问题的方式有两种,一种是从训练语料库中完全杜绝这些有害信息,但在当前的水平下比较困难;另一种是在训练的基础上对大语言模型进行有针对性的微调。

研究界通常将这一问题称作模型的“对齐”,提出模型回答在三个维度上需要对齐:有帮助性、诚实性以及无害性。基于这一观点,InstructGPT模型使用人工标注的问答数据对GPT-3进行微调,发现这种微调甚至能够帮助70亿参数量的模型生成比原来1750亿参数量模型对人类问题更有帮助的回答。这证明基于人类反馈的有监督微调(Supervised Fine-Tuning, SFT)的重要性。同时,InstructGPT使用基于人类反馈的强化学习(Reinforcement Learning from Human Feedback, RLHF)^①对模型进行进一步调整。用此方法,人类标注者需要标注一定量的回答偏好数据,基于这些数据训练合适的奖励函数对模型的回答进行自动打分评估,从而进行基于强化学习的模型优化。可以发现,ChatGPT已能针对一部分可能产生有害回答的问题选择拒绝回答的行动。

当前,对大语言模型微调目标并不唯一。例如,Anthropic针对模型的安全性专门标注了“安全/非安全”的对比数据进行微调^②,Codex将模型在代码文本上进行微调使模型具备一定的编程能力^③,DialoGPT将对话文本作为微调文本集合使模

型获得对话能力。近期,如ChatGPT Plugin等插件产品纷纷推出,允许大语言模型生成一些指令与真实搜索引擎互动检索所需信息。

如前文所述,训练和微调大语言模型对计算资源提出要求,普通研究者可能无法获得足够的资源进行实验。因此,部分研究者转而研究轻量化微调或如何在不微调模型的情况下优化模型输出。针对前者,LoRa方法可将微调过程需要调整的参数数量降低至原来的1%以下,Prefix Tuning通过在Transformer层中加入少量可调参数实现高效微调。针对后者,上下文学习以及思维链等最新研究成果可以提供有效帮助。从已有的任务样例库中选择能帮助当前模型进行任务的样例,并设计合适的输入模板将这些样例嵌入,最终生成输入文本序列。相较于直接进行Few-shot提示输入,使用这种进行设计筛选的文本序列进行输入能有效提升模型输出的稳定性和下游任务性能。可以采用样例直接筛选或依托大模型进行抽取的方法。思维链通过将一目标任务拆解为多个步骤,指示模型一步步完成该任务的方式提升模型任务性能的手段。当前,对输入端进行调整获取更好的任务性能的研究方向受到学术界关注。

5. 大语言模型的未来

大语言模型仍有诸多要解决的问题。在理论层面,大语言模型压缩、组织、存储训练文本中知识的方法需进一步探究。在模型参数量不断变大时,其性能能否按照标度率的方式上升同样是个问题。同时,目前的研究进行了广泛的实验研究大语言模型涌现能力的影响以及哪些因素影响了这种现象的产生^④。在模型架构层面,微调过程很可能迫使模型损失一部分其预训练过程中掌握的语言能力,这种现象也被称为“对齐税”^⑤。如何针对海量长文本数据的持续学习过程设计更灵活的模型架构值得研

① Christiano, P.F., Leike, J., Brown, T. et al. Deep reinforcement learning from human preferences, vances in neural information processing systems, 2017 : 30.

② Bai, Y., Jones, A., Ndousse, K. et al. Training a helpful and harmless assistant with reinforcement learning from human feedback, rXiv preprint arXiv: 2204.05862, 2022.

③ Chen, M., Tworek, J., Jun, H., et al. Evaluating large language models trained on code, rXiv preprint arXiv: 2107.03374, 2021.

④ Liu, J., Shen, D., Zhang, Y., et al. What Makes Good In-Context Examples for GPT-3? eLIO 2022, 2022 : 100.

⑤ Wei, J., Bosma, M., Zhao, V., et al. Finetuned Language Models are Zero-Shot Learners, ternational Conference on Learning Representations, 2021

究。在模型安全性方面，有研究团队正在使用人工对抗的方式提升模型的回答安全性^①，如何避免大模型输出个人隐私或有悖社会道德的回答仍需关注。此外，模型的回答看似正确实则毫无根据的“幻觉”问题同样急需解决。

四、数据集及评估指标

（一）自然语言理解数据集

在进行自然语言处理任务时，数据必不可少。在监督任务中，研究者依靠带有标注标签的数据训练模型。在无监督或半监督任务中，研究者鼓励训练模型学习不带标注标签的数据集中蕴含的模式。在深度学习普及后，由于网络模型参数量的上升，为了使模型收敛且不过于拟合，任务对数据量的需求大幅提升。语料库是自然语言处理领域的文本数据集合，可从书面文本的电子化版本中进行汇编，也可从录音中进行转录获取。使用参考语料库可比较不同的语言。多语言语料库指一种语料库，包含基于相同抽样程序和不同语言类别的单语语料库的小集合。平行语料库包含一种语言的文本及其翻译为其他语言的文本，这些文本逐句对齐。语音语料库包含记录的语音和记录的转录以及每个单词在记录的语音中出现的时间。随着多模态模型的兴起，包括图像、语音、视频等多模态数据也出现在自然语言处理相关任务集中。

自预训练语言模型兴起后，研究界逐渐需要越来越多的无标注自然文本供此类大模型进行自监督语言模型训练。无标注自然文本包括新闻稿、报刊书籍、期刊会议论文以及网页文本等，由于这些文本基本由人类撰写，因此，使用这些文本进行语言模型训练是可行的。但这些数据集的质量参差不齐，例如，网页文本相比书籍文本更易出现错别

字，因为在网页上撰写评论不需审稿。因此，在大规模预训练模型研究初期，人们会尽量选择质量有保障的语料库（例如，书籍库，等等）。但从 GPT-2 等超大规模模型被提出后，人们开始将网页文本纳入数据收集范畴以满足超大规模参数量的训练需求。

笔者以自然语言处理任务为分类依据，分别介绍相应的数据集。

1. 机器翻译

机器翻译任务数据集一般是双语平行语料库，由源语言和目标语言的文本序列对组成，每一对文本序列中的两段文本互为对方在各自语言下的高质量翻译。

（1）WMT 机器翻译数据集：历届机器翻译大会开源的 WMT 机器翻译平行语料库是机器翻译任务中最常用的数据集。WMT 数据集开源了多个版本，每个新版本中都会包含新的几种双语对照平行语料库。例如，2014 年开源的 WMT-14 数据集包含英—德、英—法、英—捷三种双语平行语料^②，而在 WMT-16 中加入了英—罗马尼亚、英—俄的双语翻译平行语料库^③。

（2）欧洲议会议事程序平行语料库^④：Europarl 平行语料库是从欧洲议会会议记录中提取的 21 种欧洲语言的平行文本语料库（1996 — 2011 年）。它包括 21 种欧洲语言版本，根据语言组合不同，平行句子的数量在 400K — 2M 间。

（3）Flore-101^⑤：FLORES 评估基准数据集由专业翻译人员通过精心控制的过程，翻译英文维基百科中的 3001 个句子，覆盖各种主题和领域，并翻译为 101 种语言。该数据集使模型在低资源语言长尾上的质量可以更好地被评估，包括多语种对多语种翻译系统的评估，因为所有翻译都是多语言对齐的。通过公开发布高质量、高覆盖率的数据集，旨

① Perez, E., Huang, S., Song, F., et al. Red teaming language models with language models, rXiv preprint arXiv: 2202.03286, 2022.

② Bojar, O., Buck, C., Federmann, C., et al. Findings of the 2014 workshop on statistical machine translation, proceedings of the ninth workshop on statistical machine translation, 2014: 12-58.

③ Bojar, O., Chatterjee, R., Federmann, C., et al. Findings of the 2016 conference on machine translation, proceedings of the First Conference on Machine Translation: Volume 2, Shared Task Papers, 2016: 131-198.

④ Koehn, P., Och, F.J., Marcu, D. Statistical phrase-based translation, university of Southern California Marina Del Rey Information Sciences Inst, 2003.

⑤ Goyal, N., Gao, C., Chaudhary, V., et al. The flores-101 evaluation benchmark for low-resource and multilingual machine translation, transactions of the Association for Computational Linguistics, 2022: 522-538.

在促进机器翻译社区及其他领域的进展。

(4) 机器翻译嘈杂文本 (MTNT)^①: 机器翻译嘈杂文本数据集是机器翻译数据集, 由 Reddit 上的嘈杂评论和专业来源的翻译组成。翻译在法语、日语之间, 每种语言的句子数在 7000 — 37000 之间。

2. 文本问答

文本问答任务要求从给定的文本中回答特定问题的答案, 对于不同类型的文本问答任务要求不同, 例如, 对开放领域的问答任务, 要求模型具备更强的知识表示和推理能力, 对特定领域的问答任务, 要求模型具备更深入的领域知识和专业术语理解能力。

(1) HotpotQA^②: HotpotQA 是收集在英语维基百科上的问答数据集, 包含约 11.3 万个众包问题, 这些问题需要维基百科两篇文章的引言段落才能回答。数据集中的每个问题都有两个材料段落以及这些段落中的句子列表, 众包工作者将其确定为回答问题所需的支持事实。

(2) SQuAD^③: 斯坦福问答数据集 (SQuAD) 是从维基百科文章中提取的问答对的集合。在 SQuAD 中, 问题的正确答案可能源自材料文献的任何地方。由于这一数据集中的问答文本是在众包平台上获取的, 因此, 它比其他一些问答数据集更为多样。SQuAD 1.1 包含 536 篇文章中的 107785 个问答对。最新版本的 SQuAD2.0 将 SQuAD1.1 中的 10 万个问题与众包工作者以类似于可回答问题的形式恶意撰写的 5 万多个不可回答的问题相结合。

(3) MS MARCO^④: MS MARCO (微软机器阅读理解) 是一个专注于搜索中进行深度学习的数据集合。第一个数据集是一个问答数据集, 包含 10

万个真实的 Bing 问题和一个人工生成的答案。该数据集随着时间的推移不断扩充, 后续扩展为包含约 100 万个问题的数据集、自然语言生成数据集、段落排名数据集、关键短语提取数据集、爬行数据集和会话搜索阅读理解数据集。

(4) RACE^⑤: 阅读理解和考试 RACE 数据集是一个机器阅读理解数据集, 由英语考试中的 27933 篇文章和 97867 道题组成, 针对 12 — 18 岁的中国学生。RACE 由两个子集组成, RACE-M 和 RACE-H, 分别来自中学和高中考试。RACE-M 有 28293 个问题, RACE-H 有 69574 个单项选择题。每道题有 4 个备选项, 只有一个选项正确。RACE 数据源并非来自众包平台, 而是专门聘请人类阅读技能考试相关专家进行设计。

(5) CNN/Daily mail^⑥: “美国有线电视新闻网 / 《每日邮报》” 是一个文本摘要数据集。其中包含的摘要段落均由美国有线电视新闻网和《每日邮报》网站上的新闻故事生成。针对每个摘要故事段落, 系统会抽取一个事实并掩盖其中一项信息作为提问内容, 希望系统能根据给定文段回答填空。作者发布从这些网站抓取、提取并生成对段落和问题的脚本。根据其脚本定义, 语料库共有 286817 个训练对、13368 个验证对和 11487 个测试对。训练集中的源文档平均有 766 个单词, 跨度有 29.74 个句子, 摘要由 53 个单词和 3.72 个句子组成。

3. 语言模型建模

对语言模型的建模需要无标号的由人类撰写的自然文本。由于大语言模型的兴盛, 网络文本同样被纳入使用范畴。

(1) Common Crawl: Common Crawl 组织开源的同名数据集是一个海量的、非结构化的、多语言的网页数据集。它包含超过 8 年的网络爬虫数据

① Michel, P., Neubig, G. MTNT: A Testbed for Machine Translation of Noisy Text, proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 2018 : 543-553.

② Yang, Z., Qi, P., Zhang, S., et al. HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering, proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 2018 : 2369-2380.

③ Rajpurkar, P., Zhang, J., Lopyrev, K., et al. SQuAD: 100, 000+ Questions for Machine Comprehension of Text, proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing, 2016 : 2383-2392.

④ Nguyen, T., Rosenberg, M., Song, X., et al. MS MARCO: A human generated machine reading comprehension dataset, hoice, 2016, 2640 : 660.

⑤ Lai, G., Xie, Q., Liu, H., et al. RACE: Large-scale Reading Comprehension Dataset From Examinations, proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, 2017 : 785-794.

⑥ Nallapati, R., Zhou, B., Dos Santos, C., et al. Abstractive Text Summarization using Sequence-to-sequence RNNs and Beyond, proceedings of the 20th SIGNLL Conference on Computational Natural Language Learning, 2016 : 280-290.

集,拥有 PB 级规模^①。Common Crawl 组织定期爬取互联网上的网页,并将网页内容存储在 Amazon S3 存储桶中。这些数据可以通过 API 或直接下载使用,并可以通过许多不同的格式进行处理,例如,WARC (Web ARChive) 和 JSON。这些数据通常包括文本、图像和元数据等内容。

(2) WikiText^②: WikiText 语言建模数据集是从维基百科上一组经过验证的好文章和特色文章中提取的超过 1 亿个词或 Token 的集合。该数据集可在知识共享署名共享许可证下获得。与宾夕法尼亚树库 (Penn TreeBank) 的预处理版本相比, WikiText-2 大 2 倍多, WikiText-103 大 110 多倍。WikiText 数据集还具有更大的词汇表,并保留了原始文本中的大小写、标点符号和数字。由于该数据集由完整的文章组成,因此,适合可以利用长期依赖关系的模型。

(3) Book Corpus^③: Book Corpus 是一个大规模的文本语料库,其中,包含超过 11 万本电子书的文本 (约 7400 万句,整体大小 4.6GB 左右)。这些电子书涵盖了各种主题和领域,包括小说、非小说、传记、技术和科学等,涉及 16 个不同的主题 (例如,浪漫主义、历史、冒险,等等)。

(4) Pushshift^④: Pushshift 是一个社交媒体数据收集、分析和归档平台,自 2015 年开始收集 Reddit 评论网站上的文本数据。Pushshift 的 Reddit 数据集实时更新,包括 Reddit 成立时的历史数据。除每月转储外,Pushshift 还提供计算工具,以帮助搜索、聚合和对整个数据集执行探索,能大幅减少研究人员的数据收集和清洗时间。

4. 文本分类

文本分类数据集涉及如情感分析、主题识别、

垃圾邮件过滤、媒体分析等子任务领域的诸多带有标注的语料库。

(1) SST: 斯坦福情感树库 SST 是一个带有完全标记的分析树语料库,可对语言中情感成分进行完整分析。语料库由 11855 个从电影评论中提取的单句组成,由斯坦福自然语言处理工具进行分析,获得 215154 个来自这些解析树的独特短语,每个短语由 3 名人类专家进行标注。每个短语会被标记为否定的、有点否定的、中性的、有一些积极的或积极的五种情感之一。

(2) MultiNLI^⑤: MultiNLI (多类型自然语言推理) 数据集包含 43.3 万个句子对,这些句子对都带有文本蕴涵信息。MultiNLI 提供了 10 种不同类型的英语书面和口语数据 (包括日常沟通、电话内容、报警电话,等等)。

(3) Yahoo! Answer^⑥: “雅虎回答”话题分类数据集包含 10 个话题的网络文本。每类话题数据集包含 14 万个训练样本和 6000 个测试样本。在收集问答文本和其他元信息的过程中,该数据集仅挑选最佳的答案内容以及该问答文本最主要的话题种类信息进行收录。

(4) IMDb^⑦: IMDb 电影评论数据集是一个二元情感分析数据集,由来自互联网电影数据库 IMDb 的 5 万条评论组成,这些影评会被人工标记为正面或负面两种情绪倾向中的一种。正负样本数量相同,且数据集仅收录了显著情绪倾向的评论,即满足负面评价的得分低于 5 分,满足正面评价的得分高于 6 分 (满分 10 分)。每部电影包含的评论不超过 30 条,数据集包含其他未标记的数据。

(二) 自然语言处理任务评估手段

在拥有数据集后,自然语言处理任务的一个必

① Wenzek, G., Lachaux, M.A., Conneau, A., et al. CCNet: Extracting High Quality Monolingual Datasets from Web Crawl Data, roceedings of the Twelfth Language Resources and Evaluation Conference, 2020 : 4003-4012.

② Stephen, M., Caiming, X., James, B., et al. Pointer sentinel mixture models, Proceedings of ICLR, 2017.

③ Yao W, Huang R. Temporal Event Knowledge Acquisition via Identifying Narratives, Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers), 2018 : 537-547.

④ Baumgartner J, Zannettou S, Keegan B, et al. The pushshift reddit dataset, Proceedings of the international AAAI conference on web and social media, 2020 : 830-839.

⑤ Williams A, Nangia N, Bowman S. A Broad-Coverage Challenge Corpus for Sentence Understanding through Inference, Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers), 2018 : 1112-1122.

⑥ Zhang, X., Zhao, J., LeCun Y. Character-level convolutional networks for text classification, Advances in neural information processing systems, 2015 : 28.

⑦ Maas A, Daly R E, Pham P T, et al. Learning word vectors for sentiment analysis, Proceedings of the 49th annual meeting of the association for computational linguistics: Human language technologies, 2011 : 142-150.

然需求即对构建的模型进行性能评估。在大规模语言模型兴起前,自然语言处理领域中的各任务大多有针对各自任务的自动评分(Metrics)计算方法,这些方法针对特定任务关注的模型能力进行特异性评估。研究者可以各自选用合适的测试集进行测评并汇报评分结果。但在大规模语言模型兴起后,更多的测试基准集(Task Benchmark)被提出。这些基准集会收录多个自然语言理解或自然语言生成方向的评测数据集。研究者将训练好的模型在所收录的测试集上依次进行测试并汇报所有评测结果作为性能参考。相较单一领域自由选择数据集进行指标评测,这种任务集能让研究者统一指标评测数据集以及评测指标,帮助研究者更好地了解训练的语言模型在各任务上的能力。

1. 自动评估指标

(1) BLEU: BLEU(双语评估替补)分数是评估一种语言翻译成另一种语言的文本质量的指标。它将“质量”的好坏定义为与人类翻译结果的一致性程度。BLEU使用一种修正的精确度形式比较翻译候选和多个翻译参考之间的异同,其定义为:翻译句子中的短语在参考句子中的比例。首先,根据N-gram将语料划分为包含单词数量的短语,例如,1-gram(Unigram)将语料划分为单个单词的短语。其次,统计这些短语在参考翻译中出现的次数。最后,除以总划分数,得到BLEU-1分数。Unigram的准确率可以用于衡量单词翻译的准确性,更高阶的N-gram准确率可用于衡量句子的流畅性。BLEU的缺点是它倾向选择更短的翻译,并且无法处理没有单词界限(例如,汉语)的语言。

(2) ROUGE^①: ROUGE(Recall-Oriented Understudy for Gisting Evaluation)是一种评估自动生成摘要或翻译与人类生成的参考摘要或翻译之间相似度的度量方法。与BLEU不同,ROUGE仅考虑召回率,即不注重翻译是否流畅,只关注翻译的准确性。ROUGE包含多个指标,包括ROUGE-1、ROUGE-2、ROUGE-L,等等。其中,ROUGE-1评估系统给出的摘要和参考摘要之间的Unigram重叠,ROUGE-2评估系统给出的摘要和参考摘要之间的Bigram重叠,ROUGE-L基于最长公共子序

列(LCS)的统计指标,自动识别序列N-gram中最长的共现词。

(3) METEOR^②: METEOR(Metric for Evaluation of Translation with Explicit Ordering)是一种用于机器翻译评价的指标。相较于常用的BLEU和ROUGE等评价指标,METEOR更多采用自然语言处理技术以提高评价结果的准确性。该指标通过对翻译结果和参考翻译之间的单词、短语和句子级别的匹配程度进行加权计算,以评估它们之间的相似度得分。此外,METEOR考虑其他因素,例如,语法和句法结构、词汇多样性和同义词等,以更好地评估翻译质量。METEOR评价指标通常应用于机器翻译领域,被广泛应用于翻译系统的评价和优化。它是一种广泛使用的评价指标,尤其适用于需要考虑句法和语义信息的自然语言处理任务。

(4) Exact Match: Exact Match(EM)是问答系统的一种常见的评价标准,它用以评价预测中匹配到正确答案的文本占整体答案长度的百分比。

(5) CIDEr: CIDEr是BLEU和向量该指标将每个句子视为文档,并计算TF-IDF向量,以衡量候选句子和参考句子之间的相似性。不同长度的N-gram相似度的权重由整个语料库中的TF-IDF分配,这使更常见的N-gram获得更小权重,因为它们包含的信息量更小。CIDEr的优点是它在计算相似度时考虑了不同的N-gram权重,因此,能更准确地评估翻译质量。该指标在机器翻译领域得到广泛应用,尤其适用于翻译系统的优化。

(6) 准确率、精确率、召回率、F1: 对于有明确文本对应标签的文本分类任务,可以通过计算模型预测准确率(Accuracy)、精确率(Precision)、召回率(Recall)、F1-score等分类精度分数进行评估。

(7) 存储空间占用、训练速率: 随着大规模语言模型的提出,如何在有限的资源条件下进行更高效的语言模型训练或微调成为越来越多研究者关注的问题。评估某种算法的训练时间成本或模型在训练过程中整体占用存储空间大小成为这些研究的算法性能评估手段。

① Lin C Y. Rouge: A package for automatic evaluation of summaries, Text summarization branches out, 2004: 74-81.

② Banerjee S, Lavie A. METEOR: An automatic metric for MT evaluation with improved correlation with human judgments, Proceedings of the acl workshop on intrinsic and extrinsic evaluation measures for machine translation and/or summarization, 2005: 65-72.

2. 任务基准集

当前,针对不同自然语言模型已提出诸多测试基准集,其中一些是组织举办的挑战赛类型的测试榜单。

(1) GLUE 基准集^①: 概括而言,通用语言理解评估 GLUE 是一个基准测试任务集,用于评估自然语言处理(NLP)模型在需要通用语言理解的一系列任务上的性能。GLUE 基准测试已被广泛用于 NLP 研究社区,作为比较和改进不同 NLP 模型性能的一种方式。具体而言,GLUE 任务集包含单句理解任务集 CoLA、SST,相似度与解释任务如 MRPC、QQP 以及文本推理任务 MNLI、QNLI,等等。

(2) CLUE 基准集^②: CLUE 是一个汉语理解评估基准。它由不同的 NLU 数据集组成。这是一个社区驱动的项目,汇集了 9 项任务,涵盖了几个成熟的单句/句子对分类任务以及机器阅读理解。所有任务的参考文本均为中文。

(3) MMLU 基准集^③: MMLU (Massive Multitask Language Understanding, 大规模多任务语言理解)是一项新的基准测试,旨在评估零样本和少快照设置中的模型,并衡量在训练之前获取的知识。MMLU 的目标是使基准测试更具挑战性、更接近人类的评估方式。该基准测试覆盖了 57 个不同的学科,包括 STEM、社会科学和人文科学,等等。测试的难度从初级到高级不等,并且测试了模型的世界知识和问题解决能力。MMLU 基准测试涵盖的学科范围非常广泛,从传统领域,例如,数学和历史,到更专业的领域,例如,法律和伦理。MMLU 的主题粒度和广度使其成为识别模型盲点的理想选择。

(4) 端到端文本生成挑战基准集 E2E^④: 端到端文本生成挑战是基于英语的自然语言生成任务,旨

在评估系统能否从给定的数据源中生成自然语言描述。在这一任务中,参与者需要设计和开发一个系统,该系统将根据给定的数据源(例如,数据库)生成完整和自然的句子。挑战赛的目标是提高 E2E NLG 系统的生成能力和质量,同时,推动自然语言生成技术的发展。该挑战赛有多个数据集和评估指标,最具代表性的是 E2E 数据集和 BLEU、METEOR、ROUGE 等评估指标。该挑战赛自 2017 年首次举办以来,已经吸引了来自全球各地的研究人员和机构参与,并成为评估自然语言生成技术的重要基准测试之一。

(5) SuperGLUE^⑤: SuperGLUE 是一个基准数据集,目的是对语言理解进行更加严格的测试。它与 GLUE 有相同的目标:为英语通用语言理解技术提供一个简单且不易被操纵的衡量标准。SuperGLUE 沿用了 GLUE 的基本设计,包括一个公共排行榜、八个语言理解任务、利用现有数据以及单一数字性能指标和分析工具包。同时,SuperGLUE 保留了 GLUE 中最难的两个任务,并增加了共指解析和问答的任务。

五、结 语

近年来,NLP 领域取得了显著的发展和突破,为人们在模型范式的变迁中对语言处理和理解方面带来诸多创新和进步。以机器翻译为例,早期统计机器翻译(SMT)是主导方法,它依赖于大量的双语语料库学习从一种语言到另一种语言的转换规则。但这种方法的缺点是需要大量的特征工程和领域专家知识。随着深度学习的兴起,端到端机器翻译开始取代传统的统计机器翻译模型。这些模型通过使用卷积神经网络(CNN)和循环神经网络(RNN)等结构,捕捉文本中的局部特征和上下文

① Wang A, Singh A, Michael J, et al. GLUE: A Multi-Task Benchmark and Analysis Platform for Natural Language Understanding, Proceedings of the 2018 EMNLP Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP, 2018: 353-355.

② Xu L, Hu H, Zhang X, et al. CLUE: A Chinese Language Understanding Evaluation Benchmark, Proceedings of the 28th International Conference on Computational Linguistics, 2020: 4762-4772.

③ Hendrycks D, Burns C, Basart S, et al. Measuring massive multitask language understanding, arXiv preprint arXiv: 2009.03300, 2020.

④ Novikova J, Dušek O, Rieser V. The E2E Dataset: New Challenges For End-to-End Generation, Proceedings of the 18th Annual SIGdial Meeting on Discourse and Dialogue, 2017: 201-206.

⑤ Wang, A., Pruksachatkun, Y., Nangia, N., et al. Superglue: A stickier benchmark for general-purpose language understanding systems, Advances in neural information processing systems, 2019: 32.

信息，从而提高了完成各种任务的准确性和效果。当前，Transformer 完全依赖自注意力机制，极大缓解了 RNN 的问题，能更好地处理长距离依赖和建模全局关系，进一步推动了 NLP 的发展。

基于 Transformer 的 BERT 和 GPT 等一系列大规模预训练模型，进一步提升了自然语言处理领域各个领域的性能。这些模型通过预训练和微调的方式，在大量无标签数据上学习语言的深层表示，并将这些表示应用于各种 NLP 任务，包括机器翻译。BERT 等 Transformer 编码器架构在 NLP 的各种应用任务中产生了深远影响，特别是在需要深度理解文本的任务中表现出色。其双向训练和自注意力机制使模型能更全面地理解文本上下文，例如，在 SQuAD 这样的问答任务中取得优异表现。此外，BERT 在包括情感分析、自然语言推理和语义文本相似性等在内的 9 个不同 NLP 任务组成的通用语言理解评估（GLUE）任务集上表现出色，这进一步证明了其在理解和推理文本含义方面的强大能力。GPT 等 Transformer 解码器被称为大规模语言模型，它们在生成文本、写作辅助和对话系统等生

成任务中表现出强大的能力。GPT 通过从左到右的方式进行预训练，学习了大量文本数据的语言规律。在微调阶段，GPT 可以根据特定任务的需求，例如，文本生成或文本分类，进行有针对性的训练，从而在这些任务上取得了优异表现。

此外，跨语言和多模态的研究也成为 NLP 领域的热点。随着全球交流和多语种数据的增加，需要解决不同语言之间的语言理解和翻译问题。跨语言 NLP 研究致力于开发通用的语言处理模型和方法，以便能在不同语言之间进行迁移和应用。同时，多模态研究关注如何将语言与其他模态数据（例如，图像、视频、声音等）相结合，从而实现更丰富的语义理解和交互。

自然语言处理领域的研究不断取得新的突破，为我们在语言处理、文本理解和交互方面提供了强大的工具和方法。随着技术的进一步发展和创新，可以期待更加智能和人类化的自然语言处理系统的出现，为人们的生活和工作提供更多的便利性和应用场景。

[责任编辑：曹晶晶]

[责任校对：王文秋]